

مدل سازی تعداد کاربران روزانه اپلیکیشن تحت تأثیر تبلیغات

علی تقی زاده

شماره دانشجویی: 40313008

تمامی آمار، اعداد و ادعاهای مطرح شده مستقیماً از کد های موجود در نوت بوک های پروژه استخراج شده‌اند. مجموعه‌ی کامل فایل های مربوط به پروژه نیز به صورت فشرده (ZIP) ضمیمه شده است.

۱. مقدمه و معرفی مسئله

در بسیاری از اپلیکیشن‌ها، تعداد کاربران روزانه یکی از مهمترین شاخص‌ها برای ارزیابی عملکرد محصول، میزان رشد، اثربخشی تبلیغات و رفتار کاربران است. مدیران محصول و تیم‌های بازاریابی معمولاً نیاز دارند بدانند تعداد کاربران در روزهای آینده چگونه تغییر می‌کند و چه عواملی باعث افزایش یا کاهش آن می‌شود. یکی از عوامل مهم در این زمینه، **هزینه تبلیغات روزانه** است. معمولاً با افزایش تبلیغات، تعداد کاربران جدید یا فعال افزایش پیدا می‌کند؛ اما این اثر همیشه فقط مربوط به همان روز نیست و ممکن است تبلیغات یک روز، در روزهای بعد نیز روی رفتار کاربران تأثیر بگذارد.

در این پروژه، هدف اصلی تولید و تحلیل یک دیتاست مصنوعی برای بررسی و پیش‌بینی **تعداد کاربران روزانه یک اپلیکیشن** است. داده‌ها برای یک بازه زمانی ۱۸۰ **روزه** ساخته شده‌اند تا بتوان روند تغییرات کاربران را در طول زمان بررسی کرد. از آنجا که در بسیاری از پروژه‌های آموزشی یا آزمایشی، داده واقعی در دسترس نیست، استفاده از داده مصنوعی می‌تواند راهکار مناسبی باشد. داده مصنوعی این امکان را فراهم می‌کند که یک سناریوی نزدیک به واقعیت طراحی شود و سپس روش‌های تحلیل و مدل‌سازی روی آن آزمایش شوند.

مسئله اصلی این پروژه این است که تعداد کاربران روزانه چگونه تحت تأثیر چند عامل مهم قرار می‌گیرد. این عوامل شامل **هزینه تبلیغات همان روز**، **هزینه تبلیغات روز قبل**، **گذر زمان و آخر هفته بودن روز** هستند. در دنیای واقعی، معمولاً در آخر هفته‌ها رفتار کاربران تغییر می‌کند و ممکن است زمان بیشتری برای استفاده از اپلیکیشن داشته باشند. بنابراین در این پروژه، روزهای پنج‌شنبه و جمعه به عنوان آخر هفته در نظر گرفته شده‌اند و اثر مثبتی برای آن‌ها روی تعداد کاربران تعریف شده است.

همچنین در این پروژه، هزینه تبلیغات به صورت یکنواخت در همه روزها پخش نشده است. برخی روزها بدون تبلیغات هستند، برخی روزها هزینه تبلیغات عادی دارند و برخی دیگر در قالب کمپین‌های تبلیغاتی با هزینه بالاتر تعریف شده‌اند. این ساختار باعث می‌شود داده‌ها به شرایط واقعی نزدیک‌تر شوند، زیرا در عمل نیز معمولاً تبلیغات به شکل پیوسته و ثابت انجام نمی‌شود، بلکه در بعضی دوره‌ها کمپین‌های فشرده‌تر اجرا می‌شوند.

در نهایت، تعداد کاربران با استفاده از توزیع پواسون تولید شده است. دلیل استفاده از این توزیع این است که تعداد کاربران یک متغیر شمارشی است؛ یعنی مقدار آن عدد صحیح و غیرمنفی است. توزیع پواسون باعث می‌شود تعداد کاربران علاوه بر وابستگی به عوامل اصلی، دارای نوسان تصادفی طبیعی نیز باشد. بنابراین دیتاست تولیدشده هم دارای منطق مشخص است و هم حالت واقعی‌تری نسبت به داده‌های کاملاً قطعی دارد.

۲. توضیح مدل یا فرضیات مورد استفاده

برای تولید داده های مصنوعی، چند فرض اصلی در نظر گرفته شده است. اولین فرض این است که تعداد کاربران روزانه اپلیکیشن تحت تأثیر هزینه تبلیغات قرار دارد. به همین دلیل متغیر Ad_Spend به عنوان هزینه تبلیغات روزانه تعریف شده است. فرض شده هرچه هزینه تبلیغات در یک روز بیشتر باشد، تعداد کاربران همان روز نیز افزایش پیدا می کند. این اثر در مدل با ضریب مثبت برای هزینه تبلیغات همان روز در نظر گرفته شده است.

فرض دوم مربوط به اثر تأخیری تبلیغات است. در دنیای واقعی، ممکن است کاربر تبلیغ را امروز ببیند اما فردا وارد اپلیکیشن شود یا نصب را انجام دهد. بنابراین علاوه بر هزینه تبلیغات روز جاری، متغیر Ad_Spend_Lag1 نیز تعریف شده است که نشان دهنده هزینه تبلیغات روز قبل است. این متغیر کمک می کند اثر تبلیغات با یک روز تأخیر نیز در تعداد کاربران لحاظ شود. در مدل، اثر تبلیغات روز قبل مثبت در نظر گرفته شده اما مقدار آن کمتر از اثر تبلیغات همان روز است.

فرض سوم این است که تعداد کاربران در طول زمان یک روند رشد دارد. معمولاً با گذشت زمان، آگاهی کاربران از اپلیکیشن بیشتر می شود و تعداد کاربران می تواند افزایش پیدا کند. برای نمایش این موضوع، متغیر Day در مدل قرار داده شده است. همچنین برای اینکه رشد به صورت کاملاً خطی و نامحدود نباشد، جمله درجه دوم زمان یعنی Day^2 نیز وارد مدل شده است. ضریب این جمله منفی در نظر گرفته شده تا نشان دهد سرعت رشد کاربران در طول زمان کمی کاهش پیدا می کند.

فرض چهارم مربوط به اثر آخر هفته است. در این پروژه فرض شده در روزهای آخر هفته، کاربران بیشتری از اپلیکیشن استفاده می کنند. بنابراین متغیر $is_weekend$ تعریف شده که اگر روز موردنظر پنجشنبه یا جمعه باشد مقدار 1 و در غیر این صورت مقدار 0 می گیرد. در مدل، برای این متغیر یک اثر مثبت در نظر گرفته شده است؛ یعنی آخر هفته بودن روز باعث افزایش تعداد کاربران پایه می شود.

فرمول کلی مقدار پایه یا میانگین مورد انتظار تعداد کاربران به صورت زیر است:

$$Users_Base = 100 + 3(Ad_Spend) + 1.5(Ad_Spend_Lag1) + 2(Day) - 0.01(Day^2) + 50(is_weekend)$$

در این فرمول، عدد 100 سطح پایه کاربران است. ضریب 3 اثر تبلیغات همان روز، ضریب 1.5 اثر تبلیغات روز قبل، ضریب 2 روند افزایشی زمان، ضریب منفی 0.01 کاهش شدت رشد در طول زمان و ضریب 50 اثر مثبت آخر هفته را نشان می دهد.

در مرحله نهایی، تعداد کاربران واقعی با استفاده از توزیع پواسون تولید شده است:

$$Users_t \sim Poisson(\lambda_t)$$

که در آن:

$$\lambda_t = Users_Base_t$$

استفاده از توزیع پواسون به این دلیل است که تعداد کاربران یک متغیر شمارشی است و باید عددی صحیح و غیرمنفی باشد. این توزیع باعث می شود مقدار نهایی کاربران دقیقاً برابر مقدار پایه نباشد، بلکه حول آن مقدار نوسان طبیعی داشته باشد. بنابراین مدل مورد استفاده ترکیبی از اثرات تبلیغات، زمان، آخر هفته و تصادفی بودن طبیعی داده های شمارشی است.

۳. روش تولید داده

برای شبیه‌سازی رفتار کاربران روزانه اپلیکیشن، یک دیتاست مصنوعی برای بازه زمانی ۱۸۰ روزه تولید شد. هدف از تولید این داده‌ها، ایجاد شرایطی نزدیک به واقعیت بود؛ به‌طوری‌که اثر تبلیغات، آخر هفته، روند زمانی و نوسان تصادفی کاربران در داده‌ها لحاظ شود.

سپس روزها از ۱ تا ۱۸۰ تعریف شدند و با فرض اینکه روز اول **شنبه** است، روزهای **پنج‌شنبه و جمعه** به عنوان آخر هفته مشخص شدند. برای این موضوع، متغیر `is_weekend` ساخته شد که برای روزهای آخر هفته مقدار 1 و برای سایر روزها مقدار 0 دارد.

در مرحله بعد، متغیر **هزینه تبلیغات روزانه** یا `Ad_Spend` تولید شد. ابتدا حداقل ۸۲ روز بدون تبلیغات به‌صورت تصادفی انتخاب شدند. همچنین برای واقعی‌تر شدن داده‌ها، حدود ۴۰٪ از آخر هفته‌ها از بدون تبلیغ شدن محافظت شدند تا احتمال اجرای تبلیغات در آخر هفته بیشتر باشد.

سپس حدوداً ۱۲ **کمپین تبلیغاتی سه‌روزه** ایجاد شد. در روزهای کمپین، هزینه تبلیغات از بازه ۴۰ تا ۶۰ تولید شد. برای سایر روزهای دارای تبلیغ، هزینه تبلیغات در آخر هفته‌ها از بازه ۲۵ تا ۴۰ و در روزهای عادی از بازه ۱۰ تا ۲۵ در نظر گرفته شد.

$$Ad_Spend = \begin{cases} 0 & \text{No advertising day} \\ Uniform(40,60) & \text{Campaign day} \\ Uniform(25,40) & \text{Non-campaign weekend} \\ Uniform(10,25) & \text{Regular non-campaign day} \end{cases}$$

برای لحاظ کردن اثر تأخیری تبلیغات، متغیر `Ad_Spend_Lag1` ساخته شد که برابر با هزینه تبلیغات روز قبل است. سپس مقدار پایه کاربران با استفاده از فرمول زیر محاسبه شد:

$$Users_Base = 100 + 3(Ad_Spend) + 1.5(Ad_Spend_Lag1) + 2(Day) - 0.01(Day^2) + 50(is_weekend)$$

در نهایت، تعداد کاربران روزانه با استفاده از **توزیع پواسون** تولید شد:

$$Users_t \sim Poisson(\lambda_t), \quad \lambda_t = Users_Base_t$$

جدول تولید شده ی نهایی در دیتاست:

نام ستون	نوع داده	توضیح	نقش در تحلیل
Day	Integer	شماره روز از ۱ تا ۱۸۰	متغیر زمانی
Ad_Spend	Float	میزان هزینه تبلیغات در همان روز	متغیر مستقل اصلی
Ad_Spend_Lag1	Float	هزینه تبلیغات روز قبل	متغیر مستقل با اثر تأخیری
is_weekend	Binary	مشخص می کند آخر هفته هست یا خیر	متغیر کنترلی
Users	Integer	تعداد کاربران تولیدشده برای هر روز	متغیر وابسته / هدف


۴. تحلیل داده ها و بررسی های آماری

بخش اول: تحلیل توصیفی و همبستگی داده ها:

در این بخش، داده های مربوط به تعداد کاربران روزانه اپلیکیشن و هزینه تبلیغات در بازه ۱۸۰ روزه بررسی شده اند. بر اساس آمار توصیفی، میانگین تعداد کاربران روزانه برابر با **266.88 نفر** و میانه آن **257.50 نفر** است. نزدیک بودن میانگین و میانه نشان می دهد که توزیع تعداد کاربران تا حد زیادی متعادل است، هرچند مقدار چولگی برابر با **0.641** بیانگر کمی کشیدگی به سمت مقادیر بالاتر است. همچنین مقدار کشیدگی **-0.156** نشان می دهد توزیع کاربران نسبتاً نزدیک به حالت نرمال بوده و پراکندگی بسیار غیرعادی یا قله شدید در داده ها مشاهده نمی شود. انحراف معیار کاربران نیز **83.65** است که نشان می دهد تعداد کاربران روزانه نوسان قابل توجهی دارد.

در مورد هزینه تبلیغات، میانگین هزینه روزانه برابر با **18.27 دلار** و میانه آن **14.60 دلار** است. از آنجا که میانگین از میانه بیشتر است، می توان نتیجه گرفت که در برخی روزها هزینه تبلیغات نسبتاً بالا بوده و باعث افزایش میانگین شده است. همچنین در میان ۱۸۰ روز بررسی شده، **۸۲ روز بدون تبلیغات** و **۹۸ روز همراه با تبلیغات** بوده است. این موضوع نشان می دهد که داده ها شامل هر دو حالت تبلیغاتی و غیرتبلیغاتی هستند و امکان مقایسه اثر تبلیغات بر تعداد کاربران وجود دارد.


مقایسه روزهای عادی هفته و آخر هفته نشان می دهد که رفتار کاربران در این دو گروه متفاوت است. میانگین تعداد کاربران در روزهای عادی هفته **245.95 نفر** و در آخر هفته ها **321.30 نفر** است. بنابراین، در آخر هفته ها به طور متوسط **75.35 کاربر بیشتر** ثبت شده که معادل افزایش حدود **30.6 درصدی** نسبت به روزهای عادی است.



رشد تغییرات تعداد کاربران و هزینه تبلیغات طی ۱۸۰ روز

نتایج تحلیل همبستگی نیز نشان می‌دهد که قوی‌ترین رابطه مربوط به ارتباط بین **هزینه تبلیغات همان روز و تعداد کاربران** است. ضریب همبستگی این دو متغیر برابر با **0.826** بوده که یک رابطه مثبت و قوی را نشان می‌دهد. به عبارت دیگر، با افزایش هزینه تبلیغات، تعداد کاربران نیز به طور محسوسی افزایش پیدا می‌کند. همچنین متغیر **هزینه تبلیغات روز قبل** نیز با تعداد کاربران همبستگی مثبت **0.553** دارد. این موضوع نشان می‌دهد که اثر تبلیغات فقط محدود به همان روز نیست و می‌تواند در روز بعد نیز بر تعداد کاربران تأثیرگذار باشد.

متغیر آخر هفته بودن روز نیز با تعداد کاربران همبستگی مثبت **0.405** دارد که با نتایج مقایسه میانگین‌ها همراستا است. در مقابل، متغیر زمان یا شماره روز دارای همبستگی ضعیف **0.108** با تعداد کاربران است؛ بنابراین در داده‌ها یک روند افزایشی بسیار ملایم در طول زمان دیده می‌شود، اما اثر آن نسبت به تبلیغات و آخر هفته بودن بسیار کمتر است.



ماتریس همبستگی







بر اساس این نمودار و توضیحات بالا، متغیر **Ad_Spend** قوی‌ترین همبستگی مثبت را با Users دارد، در حالی که **Day** کمترین ارتباط را نشان می‌دهد؛ بنابراین متغیرهای تبلیغاتی نقش مهمتری در پیش‌بینی کاربران دارند.

بخش دوم: تحلیل اثر تبلیغات بر تعداد کاربران:

در این بخش، رابطه بین **هزینه تبلیغات و تعداد کاربران روزانه** بررسی شد. ابتدا روزها بر اساس میزان تبلیغات به چهار دسته **بدون تبلیغات، تبلیغات کم، متوسط و زیاد** تقسیم شدند. نتایج نشان داد که با افزایش سطح تبلیغات، میانگین تعداد کاربران نیز به صورت مشخص افزایش پیدا می‌کند. میانگین کاربران در روزهای **بدون تبلیغات** برابر **210.22** نفر بود، در حالی که این مقدار در روزهای با **تبلیغات کم** به **245.10** نفر، در روزهای با **تبلیغات متوسط** به **334.35** نفر و در روزهای با **تبلیغات زیاد** به **383.89** نفر رسید. این الگو نشان می‌دهد که تبلیغات اثر مستقیم و افزایشی بر جذب کاربر دارد.

برای بررسی دقیق‌تر، روزها به دو گروه **با تبلیغات و بدون تبلیغات** تقسیم شدند. میانگین تعداد کاربران در روزهای بدون تبلیغات **210.22** نفر و در روزهای دارای تبلیغات **314.30** نفر بود. این اختلاف به معنی افزایش **104.08 کاربر** و حدود **49.5 درصد رشد** در روزهای دارای تبلیغات است. همچنین نتیجه آزمون **t-test** با مقدار $p\text{-value} \approx 0$ نشان داد که این تفاوت از نظر آماری کاملاً معنادار است و نمی‌توان آن را ناشی از تصادف دانست.

در ادامه، رابطه خطی بین تبلیغات و کاربران با استفاده از **رگرسیون** بررسی شد. در مدل ساده $Users \sim Ad_Spend$ ، ضریب تبلیغات برابر **3.41** به دست آمد؛ یعنی به طور متوسط، با هر یک واحد افزایش در هزینه تبلیغات، حدود **3.4 کاربر** به تعداد کاربران اضافه می‌شود. مقدار $R^2 = 0.6815$ نیز نشان می‌دهد که حدود **68 درصد** از تغییرات کاربران توسط تبلیغات همان روز توضیح داده می‌شود. در مدل رگرسیون چندمتغیره که علاوه بر تبلیغات امروز، **تبلیغات روز قبل** را نیز در نظر می‌گیرد، ضریب تبلیغات امروز **3.01** و ضریب تبلیغات روز قبل **1.37** بود و مقدار R^2 به **0.7919** افزایش یافت. این نتیجه نشان می‌دهد که هم تبلیغات همان روز و هم اثر تأخیری تبلیغات روز قبل، در توضیح تغییرات کاربران نقش مهمی دارند.




بخش سوم: تحلیل اثر آخر هفته و روزهای هفته بر تعداد کاربران:

در این بخش، تأثیر آخر هفته و همچنین روزهای مختلف هفته بر تعداد کاربران بررسی شد. در این پروژه، پنجشنبه و جمعه به عنوان آخر هفته در نظر گرفته شدند. نتایج نشان داد که میانگین تعداد کاربران در روزهای عادی هفته برابر 245.95 نفر و در آخر هفته برابر 321.30 نفر است. بنابراین، در آخر هفته به طور متوسط 75.35 کاربر بیشتر وجود دارد که معادل 30.6 درصد افزایش نسبت به روزهای عادی است. آزمون t-test نیز با p-value ≈ 0 نشان داد که این اختلاف از نظر آماری معنادار است.

تحلیل روزبه‌روز هفته نیز نشان داد که رفتار کاربران در تمام روزهای هفته یکسان نیست. بیشترین میانگین تعداد کاربران مربوط به جمعه (330.60) و پس از آن پنجشنبه (312.00) است. در مقابل، کمترین میانگین مربوط به دوشنبه (238.88) است. روزهای شنبه، یکشنبه، سه‌شنبه و چهارشنبه نیز در محدوده‌ای نزدیک به هم قرار دارند و میانگین آن‌ها عمدتاً بین 241 تا 255 کاربر است. این اختلاف نشان می‌دهد که الگوی رفتاری مشخصی در رفتار کاربران وجود دارد و کاربران در روزهای پایانی هفته فعالیت بیشتری در اپلیکیشن دارند.

نمودارهای توزیع نیز این نتیجه را تأیید می‌کنند. توزیع کاربران در آخر هفته نسبت به روزهای عادی به سمت مقادیر بالاتر جابه‌جا شده و میانگین آن نیز بزرگتر است. همچنین در نمودارهای سری زمانی، بسیاری از قله‌های تعداد کاربران با بازه‌های آخر هفته همزمان شده‌اند. این موضوع نشان می‌دهد که آخر هفته بودن یک متغیر مهم در پیش‌بینی تعداد کاربران است و باید در مدل‌سازی به‌عنوان یکی از ویژگی‌های اصلی در نظر گرفته شود.

بنابراین، در مدل‌سازی نهایی تعداد کاربران، لازم است متغیرهای `Ad_Spend`، `Ad_Spend_Lag1`، `is_weekend` و `day_of_week` حتماً به عنوان ورودی مدل در نظر گرفته شوند. این متغیرها در کنار ویژگی‌های زمانی مانند `lag 1` کاربران می‌توانند بخش بزرگی از تغییرات کاربران را توضیح دهند و دقت پیش‌بینی را افزایش دهند.



بخش اول: تحلیل سری زمانی تعداد کاربران:

در این بخش، رفتار تعداد کاربران به صورت سری زمانی بررسی شده تا روند، الگوهای تکرارشونده و میزان نوسانات داده بهتر شناسایی شود. نتایج تجزیه سری زمانی نشان می‌دهد که تعداد کاربران از سه بخش اصلی تشکیل شده است: **روند (Trend)**، **فصل‌مندی هفتگی (Seasonality)** و **باقیمانده یا نویز (Residual)**. مؤلفه روند در بازه‌ای بین 164.43 تا 384.00 تغییر کرده که نشان‌دهنده وجود یک روند کلی رو به بالا در طول دوره ۱۸۰ روزه است. این موضوع بیان می‌کند که در کنار نوسانات روزانه، سطح کلی کاربران در برخی بازه‌ها رشد کرده است. مؤلفه فصلی نیز در بازه 33.68- تا 61.59+ قرار دارد که وجود یک الگوی منظم هفتگی را تأیید می‌کند. همچنین انحراف معیار بخش باقیمانده برابر 63.75 است که نشان می‌دهد بخشی از تغییرات کاربران ناشی از عوامل تصادفی یا متغیرهای توضیح‌داده نشده در مدل است.

برای بررسی ایستایی سری زمانی، آزمون ADF روی متغیر تعداد کاربران انجام شد. مقدار آماره آزمون -3.5558 و مقدار $p\text{-value} = 0.0067$ به دست آمد که کمتر از 0.05 است؛ بنابراین فرض ناپایایی رد می‌شود و می‌توان گفت سری زمانی کاربران در سطح اطمینان مناسب ایستا است. همچنین پس از تقاضاگیری نیز سری زمانی همچنان ایستا باقی مانده و مقدار $p\text{-value}$ تقریباً صفر شده است. این نتیجه از نظر مدل‌سازی اهمیت زیادی دارد، زیرا بسیاری از مدل‌های پیش‌بینی سری زمانی به ایستایی داده‌ها وابسته هستند و این ویژگی، فرایند مدل‌سازی را قابل‌اعتمادتر می‌کند.

بررسی **میانگین متحرک ۷ روزه** نشان می‌دهد که روند کلی کاربران در طول زمان با وجود نوسانات روزانه، قابل مشاهده و نسبتاً هموار است. در برخی بازه‌ها، به‌ویژه در حدود روزهای میانی و بعدی دوره، سطح میانگین متحرک افزایش پیدا کرده و سپس دوباره به سطوح پایین‌تر بازگشته است. از طرف دیگر، **انحراف معیار متحرک ۷ روزه** نیز بیان می‌کند که شدت نوسانات در تمام طول دوره ثابت نبوده است. میانگین این شاخص برابر 75.67 است که نشان می‌دهد تغییرات کاربران در بازه‌های مختلف، نسبتاً قابل توجه اما به‌طور کلی قابل کنترل بوده است. بنابراین می‌توان گفت داده‌ها علاوه بر روند و الگوی هفتگی، دارای نوساناتی با شدت متوسط هستند.

تحلیل وقفه‌ها یا **Lag Analysis** نیز اطلاعات مهمی درباره وابستگی زمانی داده‌ها ارائه می‌دهد. بیشترین همبستگی بین تعداد کاربران امروز و **تعداد کاربران روز قبل** مشاهده شده است، به‌طوری‌که ضریب همبستگی در وقفه ۱ برابر 0.5109 است. این نتیجه نشان می‌دهد که تعداد کاربران هر روز تا حد زیادی به وضعیت روز قبل وابسته است. در وقفه‌های ۲ تا ۶ روز، همبستگی ضعیف و عمدتاً منفی مشاهده می‌شود که نشان‌دهنده کاهش اثر مستقیم روزهای دورتر است. در وقفه ۷ روزه، همبستگی دوباره مثبت شده و به 0.1141 می‌رسد. اگرچه این مقدار زیاد نیست، اما در کنار نمودارهای فصلی و الگوی روزهای هفته، نشان می‌دهد که یک **چرخه هفتگی** در رفتار کاربران وجود دارد.

تحلیل الگوی هفتگی نیز این نتیجه را تقویت می‌کند. میانگین کاربران در روزهای مختلف هفته یکسان نیست و اختلاف معناداری میان آن‌ها دیده می‌شود. بیشترین میانگین مربوط به **جمعه با 330.60 کاربر** و پس از آن **پنج‌شنبه با 312.00 کاربر** است، در حالی که کمترین مقدار مربوط به **دوشنبه با 238.88 کاربر** است. اختلاف بین بیشترین و کمترین مقدار حدود 91.72 کاربر است که نشان می‌دهد نوع روز هفته تأثیر مشخصی بر سطح استفاده از اپلیکیشن دارد. همچنین نمودارهای توزیع روزانه نشان می‌دهند که در روزهای پایانی هفته نه تنها میانگین کاربران بیشتر است، بلکه سطح کلی توزیع نیز به مقادیر بالاتری منتقل شده است.

در مجموع، تحلیل سری زمانی نشان می‌دهد که تعداد کاربران اپلیکیشن دارای **روند ملایم صعودی، الگوی فصلی هفتگی و وابستگی به مقادیر روز قبل** است. این یافته‌ها اهمیت استفاده از ویژگی‌هایی مانند lag 1، روز هفته

و مؤلفه‌های زمانی را در مدل پیش‌بینی کاربران تأیید می‌کنند. بنابراین، برای پیش‌بینی دقیق‌تر تعداد کاربران در روزهای آینده، باید هم‌زمان اثر روند، الگوی هفتگی و وابستگی کوتاه‌مدت بین روزهای متوالی در مدل لحاظ شود.

با توجه به نتایج تحلیل، این سری زمانی از نوع **تک‌متغیره با عوامل برونزا** است؛ زیرا متغیر اصلی مورد پیش‌بینی، تعداد کاربران روزانه است، اما متغیرهای دیگری مانند **هزینه تبلیغات، هزینه تبلیغات روز قبل، آخر هفته بودن و روز هفته** نیز روی آن اثر دارند. از طرف دیگر، داده‌ها دارای **الگوی هفتگی مشخص، وابستگی به مقادیر گذشته و روند ملایم صعودی** هستند. بنابراین این سری زمانی نه کاملاً تصادفی است و نه فقط وابسته به زمان، بلکه ترکیبی از ساختار زمانی و متغیرهای تأثیرگذار بیرونی را در خود دارد.

با توجه به این ویژگی‌ها، مناسب‌ترین انتخاب برای مدل‌سازی، مدل‌های سری زمانی دارای متغیر برونزا هستند. در میان آن‌ها، مدل **SARIMAX** یکی از بهترین گزینه‌ها برای این پروژه محسوب می‌شود. دلیل این انتخاب آن است که **SARIMAX** می‌تواند به‌صورت هم‌زمان **خودهمبستگی بین روزها، الگوی فصلی هفتگی و اثر متغیرهای بیرونی** مانند تبلیغات و آخر هفته را مدل کند.



همان‌طور که از نمودار مشخص است سری زمانی کاربران نوسان زیادی دارد، اما روند کلی در میانه بازه صعودی شده و بعد دوباره به محدوده‌ای باثبات‌تر برمی‌گردد.

الگوی فصلی هفتگی کاملاً مشخص است؛ قله‌ها و افت‌ها به‌صورت منظم تکرار می‌شوند و نشان‌دهنده رفتار دوره‌ای کاربران در آخر هفته‌ها هستند.

بخش دوم: مقایسه مدل‌های رگرسیون و SARIMAX پیش‌بینی کاربران:

در این بخش، عملکرد سه مدل مختلف برای پیش‌بینی تعداد کاربران بررسی و با یکدیگر مقایسه شده است: رگرسیون خطی ساده (Linear Regression)، رگرسیون خطی همراه با متغیر Day^2 و مدل SARIMAX. هدف از این مقایسه، انتخاب مدلی است که بتواند با کمترین خطا و بیشترین دقت، مقدار کاربران واقعی را پیش‌بینی کند.

مدل اول: LINEAR REGRESSION

بر اساس نتایج به‌دست‌آمده، مدل Linear Regression یا رگرسیون خطی ساده دارای مقدار R^2 برابر با 0.9009 است. این مقدار نشان می‌دهد که مدل می‌تواند حدود 90 درصد از تغییرات تعداد کاربران را توضیح دهد. با وجود اینکه این عدد قابل قبول است، اما مقدار خطای مدل نسبتاً بالاست. مقدار RMSE برابر با 25.60 و MAE برابر با 19.91 نشان می‌دهد که پیش‌بینی‌های این مدل به‌طور میانگین اختلاف بیشتری با مقادیر واقعی دارند. در نمودار پراکندگی نیز مشاهده می‌شود که نقاط نسبت به خط قرمز مرجع فاصله بیشتری دارند.

مدل دوم: LINEAR REGRESSION + DAY²

در مدل دوم، یعنی Linear Regression + Day²، علاوه بر متغیرهای اصلی، اثر غیرخطی زمان نیز با اضافه کردن متغیر Day² در نظر گرفته شده است. این تغییر باعث بهبود قابل توجه عملکرد مدل شده است. مقدار R^2 به 0.9619 افزایش یافته و مقدار RMSE به 15.86 کاهش پیدا کرده است. همچنین مقدار MAE برابر با 12.51 است که نسبت به مدل خطی ساده کاهش محسوسی دارد. این نتیجه نشان می‌دهد که رابطه بین زمان و تعداد کاربران کاملاً خطی نیست و اضافه کردن جمله درجه دوم توانسته روند داده‌ها را بهتر مدل کند.

مدل سوم: SARIMAX

مدل سوم، SARIMAX، یکی از مدل‌های سری زمانی است که علاوه بر وابستگی زمانی داده‌ها، امکان استفاده از متغیرهای برون‌زا را نیز فراهم می‌کند. این مدل در این مسئله عملکردی بسیار نزدیک به مدل دوم داشته است. مقدار R^2 برابر با 0.9605، RMSE برابر با 15.86 و MAE برابر با 12.52 گزارش شده است. این اعداد نشان می‌دهند که SARIMAX نیز دقت بسیار بالایی در پیش‌بینی تعداد کاربران دارد و به‌ویژه برای داده‌هایی که دارای الگوی زمانی هستند، انتخابی مناسب محسوب می‌شود. در مدل SARIMAX(2,1,2)(1,0,1,7)، بخش اول یعنی (2,1,2) به‌ترتیب نشان‌دهنده تعداد وقفه‌های خودرگرسیون، درجه تفاضل‌گیری برای ماناسازی و تعداد میانگین متحرک است، و بخش فصلی (1,0,1,7) نیز بیان می‌کند که مدل دارای یک جزء میانگین متحرک فصلی و دوره فصلی 7 روزه است.

بررسی ضرایب مدل برتر

با توجه به نتایج، مدل Linear Regression + Day² بهترین عملکرد را در بین سه مدل داشته است؛ زیرا بالاترین مقدار R^2 و کمترین مقدار MAE را ارائه کرده است. ضرایب این مدل نشان می‌دهند که:

درصد خطا	ضریب به‌دست‌آمده	ضریب اصلی (در فرمول)	نام متغیر (Feature)
-5.30%	94.6987	100	Intercept (مقدار پایه)
-0.69%	2.9793	3	Ad_Spend
3.26%	1.5490	1.5	Ad_Spend_Lag1
6.02%	2.1204	2	Day
0.22%	50.1104	50	is_weekend
-6.12%	-0.0106	-0.01	Day2


برای ارزیابی دقت و کارایی مدل‌های مورد استفاده در پیش‌بینی تعداد کاربران، سه مدل مختلف شامل **رگرسیون خطی ساده**، **رگرسیون خطی به همراه جمله درجه دوم زمان (Day^2)** و مدل **SARIMAX** با یکدیگر مقایسه شدند. این مقایسه بر اساس سه شاخص اصلی **MAE**، **RMSE** و **R²** انجام شده است.

مدل	MAE	RMSE	R ²
Linear Regression	19.91	25.60	0.9009
Linear Regression + Day²	12.51	15.86	0.9619
SARIMAX	12.52	15.86	0.9605

به‌طور کلی، نتایج نشان می‌دهد که **مدل رگرسیون خطی ساده** اگرچه عملکرد قابل قبولی دارد، اما دقت آن نسبت به دو مدل دیگر پایین‌تر است. اضافه کردن متغیر **Day²** باعث بهبود چشمگیر مدل شده و نشان داده است که الگوی رشد کاربران دارای روندی غیرخطی است. از سوی دیگر، **SARIMAX** نیز عملکردی بسیار نزدیک به مدل دوم دارد و برای تحلیل و پیش‌بینی داده‌های زمانی گزینه‌ای بسیار مناسب است.


در نهایت، با توجه به معیارهای عددی، **مدل Linear Regression + Day²** بهترین مدل انتخاب می‌شود؛ زیرا با **MAE = 12.505**، **RMSE = 15.865** و **R² = 0.9619** بهترین توازن را بین دقت و خطا ارائه داده است.

بررسی نمودار ها:




این نمودارها مقایسه مقدار کاربران واقعی و پیش‌بینی‌شده را برای سه مدل نشان می‌دهند؛ هرچه نقاط به خط قرمز نزدیک‌تر باشند، دقت مدل بالاتر است.

مدل‌های **Linear Regression + Day²** و **SARIMAX** نسبت به رگرسیون خطی ساده تطابق بهتری با داده‌های واقعی دارند و خطای پیش‌بینی کمتری نشان می‌دهند.



این نمودارها باقیمانده‌های سه مدل را نشان می‌دهند و هرچه نقاط به‌صورت تصادفی‌تر و نزدیک‌تر به خط صفر پخش شده باشند، عملکرد مدل بهتر است.

در مقایسه با رگرسیون خطی ساده، مدل‌های **Linear + Day²** و **SARIMAX** پراکندگی متعادل‌تر و خطاهای کنترل‌شده‌تری دارند که نشان‌دهنده برازش بهتر آن‌هاست.



این نمودار عملکرد مدل **SARIMAX** را در پیش‌بینی تعداد کاربران در بخش آزمون نشان می‌دهد.

خط آبی داده‌های آموزشی، خط سبز مقادیر واقعی بخش تست و خط نارنجی پیش‌بینی‌های مدل را نمایش می‌دهد؛ خط قرمز نقطه جداسازی داده‌های آموزش و آزمون است.

نزدیکی خط نارنجی به خط سبز نشان می‌دهد که مدل توانسته روند و نوسانات اصلی کاربران را با دقت خوبی دنبال کند.

نتیجه‌گیری نهایی

هدف اصلی این پروژه، پیش‌بینی تعداد کاربران بر اساس داده‌های زمانی و متغیرهای اثرگذار مانند هزینه تبلیغات، اثر تبلیغات روز قبل و آخر هفته بودن بوده است. در این راستا تلاش شد با استفاده از مدل‌های مختلف، الگویی مناسب برای تخمین رفتار کاربران استخراج شود تا بتوان از آن برای تحلیل روندها و تصمیم‌گیری دقیق‌تر استفاده کرد.

داده‌های مورد استفاده در این پروژه شامل متغیرهایی بودند که هرکدام می‌توانستند بخشی از رفتار کاربران را توضیح دهند. متغیر **Day** نمایانگر بُعد زمانی داده‌ها بود و به مدل کمک می‌کرد روند تغییرات کاربران در طول زمان را شناسایی کند. متغیر **Ad_Spend** نشان‌دهنده هزینه تبلیغات در همان روز و متغیر **Ad_Spend_Lag1** نشان‌دهنده اثر باقی‌مانده تبلیغات روز قبل بود. همچنین متغیر **is_weekend** برای بررسی تفاوت رفتار کاربران در روزهای پایانی هفته در نظر گرفته شد. نتایج نشان داد که این متغیرها همگی در بهبود کیفیت پیش‌بینی نقش مؤثری داشته‌اند و حذف هرکدام می‌توانست بخشی از اطلاعات مهم را از مدل بگیرد. در نهایت با توزیع پواسون مقدار کاربر ایجاد شد.

یکی از نکات مهم این پروژه، توجه به ماهیت سری زمانی داده‌ها بود. از آنجا که تعداد کاربران در طول روزها تغییر می‌کند، صرفاً استفاده از یک رابطه خطی ساده نمی‌تواند همه الگوهای موجود را به‌خوبی توضیح دهد. در داده‌های سری زمانی، معمولاً روند، تغییرات تدریجی، اثرات تأخیری و الگوهای وابسته به زمان اهمیت زیادی دارند. در این پروژه نیز مشاهده شد که زمان تنها یک متغیر ساده نیست، بلکه رفتار کاربران در گذر زمان دارای نوعی تغییر غیرخطی است. به همین دلیل، اضافه کردن جمله **Day²** به مدل توانست این رفتار غیرخطی را بهتر ثبت کند و عملکرد مدل را به‌صورت محسوسی بهبود دهد. این موضوع نشان می‌دهد که در تحلیل داده‌های وابسته به زمان، توجه به ساختار زمانی داده‌ها و الگوهای پنهان در آن، نقش بسیار مهمی در دقت نهایی مدل دارد.

برای مدل‌سازی، سه رویکرد اصلی مورد بررسی قرار گرفت: **رگرسیون خطی ساده**، **رگرسیون خطی همراه با جمله درجه دوم زمان و مدل SARIMAX**. رگرسیون خطی ساده به‌عنوان مدل پایه انتخاب شد تا مشخص شود در ساده‌ترین حالت، متغیرها تا چه حد قادر به توضیح تغییرات کاربران هستند. نتایج این مدل قابل قبول بود، اما مقدار خطا همچنان نسبتاً بالا باقی ماند و مشخص شد که این مدل نمی‌تواند همه پیچیدگی‌های داده را به‌خوبی پوشش دهد.

در گام بعد، با اضافه کردن متغیر **Day²**، مدل توانست روند زمانی را بهتر درک کند و همین موضوع باعث کاهش چشمگیر خطا و افزایش مقدار **R²** شد. این نتیجه نشان داد که رابطه بین زمان و تعداد کاربران کاملاً خطی نیست و بخشی از رفتار داده‌ها نیازمند مدلی انعطاف‌پذیرتر است. سپس مدل **SARIMAX** مورد استفاده قرار گرفت که علاوه بر در نظر گرفتن متغیرهای اثرگذار، ساختار زمانی داده‌ها و وابستگی بین مشاهدات متوالی را نیز لحاظ می‌کند. این مدل نیز عملکرد بسیار خوبی داشت و مقادیر **MAE** و **RMSE** آن در سطح بسیار مناسبی قرار گرفت، هرچند از نظر مقدار **R²** اندکی پایین‌تر از مدل **Linear Regression + Day²** قرار گرفت.

بررسی ضرایب مدل نهایی نشان داد که هزینه تبلیغات اثر مستقیم و مثبتی بر افزایش تعداد کاربران دارد؛ به این معنا که با افزایش بودجه تبلیغات، تعداد کاربران نیز بیشتر می‌شود. همچنین متغیر **Ad_Spend_Lag1** تأیید کرد که اثر تبلیغات تنها محدود به همان روز نیست و بخشی از آن در روز بعد نیز باقی می‌ماند. متغیر **is_weekend** نیز اثر مثبتی بر تعداد کاربران داشت که نشان می‌دهد رفتار کاربران در آخر هفته با روزهای عادی متفاوت است و معمولاً حضور یا فعالیت بیشتری وجود دارد. از سوی دیگر، وجود جمله **Day²** در مدل به‌خوبی نشان داد که رشد کاربران در طول زمان به‌صورت یکنواخت و خطی ادامه پیدا نمی‌کند و تغییرات آن دارای الگوی غیرخطی است.

در مجموع، می‌توان نتیجه گرفت که ترکیب ویژگی‌های زمانی و تبلیغاتی نقش بسیار مهمی در پیش‌بینی دقیق تعداد کاربران دارد. این پروژه نشان داد که استفاده از مدل‌های پیشرفته‌تر نسبت به رگرسیون خطی ساده، به‌ویژه در داده‌هایی با ماهیت زمانی، می‌تواند دقت پیش‌بینی را به شکل معناداری افزایش دهد.